

INFORME TÉCNICO

EDA_NLP_TroncosoMarcelo.pdf

Análisis exploratorio del corpus AG News

Pipeline de limpieza, normalización, lematización y diagnóstico estadístico

Resumen del análisis

Resumen ejecutivo del pipeline y de los principales hallazgos

Dataset analizado: AG News, con 8.000 documentos de entrenamiento y 2.000 documentos de prueba. El EDA se calcula exclusivamente sobre train para preservar la independencia del conjunto test.


Preprocesamiento aplicado: decodificación de entidades HTML, eliminación de etiquetas y URLs, conversión a minúsculas, eliminación de caracteres no alfabéticos, tokenización y lematización con SpaCy.

Resultado principal: longitud media de 35.97 tokens, mediana de 36 y percentil 95 igual a 50. El valor p95 se propone como max_len de referencia.

Las cuatro clases están balanceadas con 2000 documentos cada una. En el top 50 léxico se identificaron 36 stop-words estándar de SpaCy.

Distribución de longitud de tokens

Histograma del corpus train después del preprocesamiento



20 bi-gramas más frecuentes

Secuencias de dos tokens y frecuencia de aparición

ngram	frecuencia
of the	1410
in the	1383
for the	610
ap ap	529
to the	485
on the	462
new york	419
at the	394
have be	333
the world	307
the first	297
with the	295
on wednesday	272
on tuesday	267
and the	266
on monday	265
say on	249
on thursday	245
as the	242
to be	242

Interpretación de bi-gramas

Lectura breve de los patrones léxicos encontrados

Los bi-gramas permiten observar asociaciones frecuentes del lenguaje periodístico, como nombres de organizaciones, lugares, actores políticos o términos deportivos. Su análisis sirve como control de calidad: después de la limpieza no deberían dominar etiquetas HTML, URLs ni símbolos aislados.

20 tri-gramas más frecuentes

Secuencias de tres tokens y frecuencia de aparición

ngram	frecuencia
new york reuters	151
the united states	149
one of the	107
ap ap the	85
for the first	71
the first time	71
quote profile research	69
kill at least	57
be expect to	56
of the year	55
the world large	55
in the first	53
the new york	52
say on tuesday	51
of the season	49
of the world	47
the end of	47
the european union	47
say on wednesday	45
round of the	44


Interpretación de tri-gramas

Lectura breve de los patrones contextuales encontrados

Los tri-gramas agregan contexto y suelen representar expresiones periodísticas más específicas. Pueden aportar señales para diferenciar las categorías temáticas de AG News, especialmente cuando combinan entidades, acciones y conceptos propios de cada sección.

Distribución de clases

Cantidad de documentos por categoría en el conjunto train



Conclusión

Preparación del corpus para el modelo final

AG News contiene noticias breves y presenta un balance perfecto entre sus cuatro clases: Business, Sci_Tech, Sports y World. Los principales desafíos del corpus son la variabilidad morfológica, la presencia potencial de URLs, etiquetas HTML, números y signos de puntuación, además de las diferencias de longitud entre documentos. El pipeline aborda estos problemas en un orden reproducible: primero decodifica entidades HTML y elimina ruido estructural; luego normaliza a minúsculas, conserva únicamente caracteres alfabéticos y aplica lematización con SpaCy. El histograma y el percentil 95 permiten elegir un `max_len` basado en los datos, evitando padding excesivo y truncaciones arbitrarias. Los bi-gramas y tri-gramas muestran patrones periodísticos útiles y no evidencian residuos HTML o URLs. En consecuencia, el corpus queda preparado para vectorización y modelado. Como el conjunto de prueba se mantiene separado, las estadísticas obtenidas no contaminan la evaluación posterior.