

INFORME TECNICO

Clasificacion de noticias con NLP clasico y LoRA

Proyecto final consolidado | AG News

Autor: Marcelo Troncoso

Modelo avanzado: distilbert-base-uncased

Comparacion sobre el mismo conjunto de test (2.000 noticias)

TF-IDF + LogisticRegression frente a DistilBERT + LoRA

Resultado principal: el baseline clasico obtiene el mejor F1 macro en este corpus.

1. Problema, datos y pipeline end-to-end

Problema. Clasificar titulares y textos breves de AG News en cuatro temas: Business, Sci_Tech, Sports y World. El objetivo es establecer un baseline interpretable y contrastarlo con transfer learning eficiente para elegir una solución según rendimiento, costo y complejidad operativa.

Datos y protocolo. El corpus contiene 8.000 ejemplos de entrenamiento y 2.000 ejemplos de test, con 500 observaciones por clase en test. El train se divide estratificadamente en 6.400 ejemplos de ajuste y 1.600 de validación. El test se reserva hasta la evaluación final y es exactamente el mismo para ambos modelos.

Pipeline clásico. Se desescapan entidades HTML, se eliminan etiquetas, URLs, caracteres no alfabéticos y espacios redundantes; luego se normaliza a minúsculas, se tokeniza y lematiza con spaCy en `_core_web_sm`. Scikit-Learn recibe esa secuencia lematizada y su `TfidfVectorizer` construye el vocabulario de unigramas y bigramas; no utiliza tokens especiales ni embeddings densos. TF-IDF usa `stop_words='english'`, `min_df=2`, `max_df=0.95`, `sublinear_tf=True`, 20.000 features máximas y unigramas/bigramas. La regresión logística se ajusta sobre matrices dispersas.


Pipeline Transformer. DistilBERT recibe el texto original normalizado a minúsculas; la tokenización subword (WordPiece) de Hugging Face agrega los tokens especiales [CLS] y [SEP], trunca a `max_length=128` tokens y realiza padding dinámico por batch (longitud variable según el lote, nunca mayor a 128). Cada token se convierte en un embedding denso contextual; las etiquetas se mapean a enteros y el test no participa en entrenamiento ni selección de hiperparámetros.

2. Baseline: TF-IDF + LogisticRegression

La configuracion seleccionada alcanzo F1 macro de validacion 0.8927 frente a 0.8902 de unigramas. El modelo final se reajusto sobre los 8.000 ejemplos de train y produjo una matriz TF-IDF de 20.000 columnas.

En test, Sports es la clase mas separable (F1=0.96), mientras Business (F1=0.85) y Sci_Tech (F1=0.87) concentran el desafio. La razon es el vocabulario compartido de empresas, mercados, tecnologia y resultados financieros. La representacion pondera terminos y n-gramas discriminativos, pero no modela relaciones contextuales largas.

Clase	Precision	Recall	F1	Support
Business	0.85	0.87	0.86	500
Sci_Tech	0.87	0.87	0.87	500
Sports	0.95	0.96	0.96	500
World	0.91	0.89	0.90	500
accuracy			0.90	2000
macro avg	0.90	0.90	0.90	2000
weighted avg	0.90	0.90	0.90	2000




3. Solucion avanzada: DistilBERT + LoRA

Modelo base: distilbert-base-uncased. Se entrena un clasificador de cuatro clases sobre representaciones contextualizadas generadas por Transformer. En cada capa, los attention heads calculan relaciones entre tokens; LoRA congela los pesos preentrenados y aprende actualizaciones de bajo rango en las proyecciones q_{lin} y v_{lin} .

Configuracion: rank (r)=8, α =16 ($\alpha/r=2$), dropout=0.1, bias='none', learning_rate=2e-5, batch de train=16, batch de evaluacion=32, weight_decay=0.01 y 3 epocas. Se conserva el mejor checkpoint segun F1 macro de validacion.

El modelo tiene 67,697,672 parametros totales y solo 741,124 entrenables (1.09%). El entrenamiento tomo 4.50 minutos en una GPU GTX 1650 Ti. Durante cada paso, la perdida de clasificacion se propaga mediante backpropagation; el optimizador actualiza solo las matrices LoRA y mantiene congelados los embeddings y pesos originales. La validacion selecciono la epoca 2 (F1 macro=0.8776); la epoca 3 mantuvo practicamente el mismo rendimiento (0.8771), sin evidencia de una mejora sustancial.




4. Evaluacion comparativa sobre el mismo test

Modelo	Accuracy	F1 macro	F1 ponderado
TF-IDF + LogisticRegression	0.8960	0.8960	0.8965
DistilBERT + LoRA	0.8875	0.8874	0.8900

Lectura. TF-IDF supera a LoRA por 0.0086 puntos de F1 macro (0.96% relativo). El test esta perfectamente balanceado (500 ejemplos por clase), por lo que F1 ponderado y F1 macro coinciden en ambos modelos; aun asi se reporta F1 ponderado explicitamente, como buena practica frente al desbalance de clases, en lugar de defender el proyecto solo con accuracy. Sports es la clase mas robusta en ambos modelos. LoRA mejora recall de Sci_Tech (0.88 frente a 0.87), pero pierde precision/recall en Business y no compensa el diferencial global.

Eficiencia. El baseline requirio 1.53 segundos para reajustar TF-IDF + LogisticRegression sobre train (excluyendo el preprocesamiento NLP, ya calculado), mientras LoRA requirio 266.00 segundos de GPU para 3 epocas de fine-tuning. LoRA reduce la cantidad de parametros actualizados a 1.09%, pero no elimina el costo de ejecutar un Transformer ni su cadena de dependencias (GPU, tokenizador, PEFT). El baseline obtiene mejor F1 (0.8960 vs. 0.8874) y menor costo medido; por eso es la eleccion recomendada para este corpus.



5. Interpretabilidad: que ve cada modelo

El baseline TF-IDF es una caja transparente: cada prediccion puede explicarse por los pesos que la regresion logistica asigna a los terminos y bigramas presentes en el texto. Su limite estructural es que ignora el orden de las palabras mas alla de los bigramas y no desambigua por contexto extendido.

Ejemplo real de error del baseline en el test (misma observacion usada para evaluar ambos modelos):

"Symantec Said to Be in Talks for Veritas. Symantec, which produces the Norton line of computer products, is in talks to acquire Veritas Software, a maker of data backup programs...."

Etiqueta real: Business | Prediccion del baseline: Sci_Tech

Lectura. El texto mezcla vocabulario tipico de ambas categorias (empresas, productos y tecnologia), por lo que TF-IDF, al ponderar terminos de forma independiente, se inclina hacia la clase con mayor peso lexico agregado. Un Transformer con self-attention puede, en principio, atender simultaneamente al sujeto de la oracion, al verbo principal y al contexto discursivo (por ejemplo, si la nota describe una decision corporativa o un avance tecnico), resolviendo la ambigüedad mediante relaciones de largo alcance que el bag-of-words no representa.

Honestidad de la evidencia. En esta corrida, DistilBERT + LoRA no elimino toda la confusion Business/Sci_Tech (ver matrices de la seccion 4): la mejora de recall en Sci_Tech sugiere que captura parte de esta señal, pero no se dispone de la prediccion puntual del modelo LoRA para este ejemplo especifico, por lo que no se afirma que lo haya resuelto; se documenta como el tipo de caso donde la atencion contextual deberia aportar valor.

6. Conclusiones, limitaciones y referencias

Conclusiones. En AG News, un problema de cuatro clases con vocabulario muy distintivo, TF-IDF + LogisticRegression fue la mejor decision tecnica: alcanza F1 ponderado 0.8960 con una arquitectura compacta, interpretable, facil de serializar y con un ajuste medido en 1.53 segundos. DistilBERT + LoRA demuestra adaptacion eficiente en parametros, porque solo actualiza 1.09% de ellos, pero su F1 ponderado de 0.8874 no supera al baseline ni en metricas ni en tiempo de ajuste del modelo. La semantica contextual no aporta una ventaja medible cuando los terminos y bigramas ya separan bien las categorias.

Limitaciones. Se dispone de una sola corrida LoRA (sin repeticiones con distintas semillas) y no se registro consumo de memoria de GPU, por lo que la comparacion de eficiencia es parcial. El test es balanceado y relativamente pequeno; no permite estudiar robustez ante drift, clases raras o textos fuera de dominio. Ademias, no se conserva el modelo LoRA serializado, por lo que la seccion de interpretabilidad no pudo contrastar una prediccion puntual de LoRA sobre el mismo ejemplo del baseline. La matriz de confusion es evidencia de comportamiento agregado, no una explicacion causal de la atencion.

Mejoras futuras. Repetir con varias semillas y registrar tiempo, memoria y latencia de ambos modelos; explorar r, alpha, learning rate y max_length; calibrar probabilidades; evaluar textos mas ambiguos y aplicar explicabilidad local (por ejemplo, perturbacion de tokens o Integrated Gradients). Para una eleccion productiva tambien deben medirse costo por prediccion y requisitos de despliegue.

Referencias. Zhang et al. (2015), Character-level Convolutional Networks for Text Classification. Hu et al. (2022), LoRA: Low-Rank Adaptation of Large Language Models. Sanh et al. (2019), DistilBERT, a distilled version of BERT. Documentacion de scikit-learn, Hugging Face Transformers y PEFT. Dataset AG News, corpus de noticias de AG utilizado con fines academicos.