

Checkpoint NLP III

Clasificación con Fine-Tuning Eficiente mediante LoRA

Autor: Marcelo Troncoso

Dataset: AG News (clasificación de tópicos, 4 clases)

Modelo base: distilbert-base-uncased

Estructura: 1. Resumen de arquitectura 2. Configuración PEFT 3. Resultados y comparativa 4. Conclusiones

1. Resumen de arquitectura

Modelo base: distilbert-base-uncased

Justificación: el corpus AG News está en inglés y normalizado a minúsculas, por lo que no se requiere un modelo multilingüe. DistilBERT retiene ~97% del rendimiento de BERT-base con ~40% menos parámetros y mayor velocidad de inferencia/entrenamiento, lo cual es clave dado el hardware disponible para este checkpoint (una única GPU de gama media). Modelos más grandes (BERT-base, RoBERTa-base) habrían incrementado el costo computacional sin una mejora justificada para una tarea de clasificación de 4 clases con vocabulario muy diferenciado entre categorías.

Parámetros totales del modelo: 67,697,672

Parámetros entrenables (adaptadores LoRA): 741,124

Porcentaje entrenable: 1.09% (cumple el criterio de eficiencia paramétrica, < 3%).

Tiempo de entrenamiento: 266.00 segundos (4.43 minutos) para 3 épocas.

2. Configuración PEFT (LoRA)

Rango (r): 8

Factor de escala (lora_alpha): 16 (razón $\alpha/r = 2.0$)

Dropout: 0.1

Módulos objetivo: q_lin, v_lin

Bias: none

Argumentación: la clasificación de tópicos de AG News es una tarea de complejidad baja-media (4 clases con vocabulario bien diferenciado), por lo que un rango $r=8$ alcanza para capturar los patrones específicos de la tarea sin sobreajustar ni añadir parámetros innecesarios. Un $\text{lora_alpha}=16$ escala las actualizaciones lo suficiente para que el adaptador tenga impacto real durante el entrenamiento, manteniendo la estabilidad numérica. El dropout de 0.1 regulariza el adaptador dado el tamaño moderado del dataset (8.000 ejemplos de entrenamiento). Los módulos q_lin y v_lin corresponden a las proyecciones de consulta y valor de la atención, el punto estándar de inserción de adaptadores LoRA según el paper original, ya que concentran la mayor parte de la capacidad discriminativa del mecanismo de atención con el menor número de parámetros entrenables.

Pérdida final de entrenamiento (train_loss): 0.5183

Pérdida de validación (eval_loss): 0.3577

Métricas de validación (mejor checkpoint, época seleccionada por F1 macro):

Accuracy: 0.8781

Precision macro: 0.8781

Recall macro: 0.8781

F1 macro: 0.8776

3. Resultados y comparativa (conjunto de test)

Modelo	Precisión (macro)	Recall (macro)	F1 (macro)
TF-IDF + LogisticRegression	0.8962	0.8960	0.8960
DistilBERT + LoRA	0.8875	0.8875	0.8874

Reporte de clasificación - DistilBERT + LoRA (test):

	precision	recall	f1-score	support
--	-----------	--------	----------	---------

Business	0.83	0.82	0.83	500
Sci_Tech	0.85	0.88	0.86	500
Sports	0.96	0.98	0.97	500
World	0.90	0.88	0.89	500
accuracy			0.89	2000
macro avg	0.89	0.89	0.89	2000
weighted avg	0.89	0.89	0.89	2000

Reporte de clasificación - TF-IDF + LogisticRegression (test):

	precision	recall	f1-score	support
--	-----------	--------	----------	---------

Business	0.85	0.86	0.85	500
Sci_Tech	0.87	0.87	0.87	500
Sports	0.95	0.96	0.96	500
World	0.91	0.89	0.90	500
accuracy			0.90	2000
macro avg	0.90	0.90	0.90	2000
weighted avg	0.90	0.90	0.90	2000

4. Conclusiones

F1 macro TF-IDF + LogisticRegression: 0.8960

F1 macro DistilBERT + LoRA: 0.8874

Diferencia: -0.0086

En esta ejecución, el baseline TF-IDF + LogisticRegression superó levemente a DistilBERT + LoRA en el conjunto de test. Para una tarea de clasificación de tópicos con vocabulario muy distintivo entre clases como AG News, la representación TF-IDF ya captura casi toda la señal discriminativa, por lo que la capacidad contextual adicional de un Transformer no se traduce en una mejora de métricas.

Sin embargo, el enfoque LoRA demuestra su valor real en eficiencia: solo se entrena 1.09% de los parámetros del modelo (741,124 de 67,697,672), lo que permite adaptar un Transformer preentrenado en pocos minutos de GPU sin actualizar todos sus pesos.

Conclusión técnica: en este caso concreto, el costo computacional adicional del fine-tuning no se justifica frente al modelo clásico por la mejora de métricas obtenida (de hecho, el clásico rindió mejor). El valor de LoRA se justificaría mejor en tareas de mayor complejidad semántica (matices, ambigüedad, dominios donde el vocabulario superficial no alcanza), donde la capacidad contextual del Transformer sí aportaría una ventaja medible frente al costo adicional de entrenamiento e inferencia.